Aeropuertos - Operaciones y Pasajeros

October 31, 2024

1 Aeropuertos - Operaciones y Pasajeros

Creado por:

- **V. D. Betancourt**

1.1 Introducción

1.1.1 Objetivo

El presente proyecto tiene por objetivo analizar los **datos operativos** presentados en distintos aeropuertos, lo cual incluye operaciones comerciales y generales, así como el flujo de pasajeros, el número de aerolíneas, y los destinos nacionales e internacionales.

Adicionalmente, se propone un modelo para obtener **predicciones** sobre el comportamiento de esta operativa. Dicho modelo está basado en **Redes Neuronales (Neural Networks)**.

1.1.2 Descripción

El análisis de la operativa en distintos aeropuertos depende de la información disponible y la calidad de la misma.

En ese proyecto se han creado **datos sintéticos** que constan de **11 variables (columnas)**, para un período parametrizable de fechas mensuales.

1.2 Settings

1.2.1 Importar Librerías

[ ]:
```
# Importar Librerías
import pandas as pd
import numpy as np
from datetime import datetime

# Librerías para Visualización de datos
import matplotlib.pyplot as plt
import seaborn as sns

# Librerías para Redes Neuronales
from sklearn.preprocessing import MinMaxScaler, LabelEncoder
from sklearn.model_selection import train_test_split
```

```
from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, Dense, Dropout
from tensorflow.keras.optimizers import Adam
```

1.3 Generar Datos Sintéticos

Se creará un dataset llamado **datos_aeropuertos.csv**, que contendrá **"datos sintéticos"** (generados aleatoriamente) con los siguientes **11 variables (columnas)**:

- **'fecha'**: Es la fecha de cada registro (fila) que comprenderá el rango del **'2022-03-31'** al **'2024-03-31'**, y siempre corresponderán a las fechas del último día del mes.
- **'nombre_aeropuerto'**: Se refiere al nombre del aeropuerto, el cual, para simplificar este análisis, corresponderán a 12 nombres de la forma: **'Aeropuerto_1'**, **'Aeropuerto_2'**, …, **'Aeopuerto_12'**.
- **'tipo_aeropuerto'**: Se considerarán solamente aeropuertos del tipo **'Internacional'**.
- **'numero_aerolineas'**: Será un número aleatorio entre 5 y 20 aerolíneas.
- 'destinos_nacionales': Será un número aleatorio entre 5 y 30 destinos nacionales.
- **'destinos_internacionales'**: Será un número aleatorio entre 1 y 10 destinos internacionales.
- **'destinos_total'**: Es la suma de 'destinos_nacionales' y **'destinos_internacionales'**.
- **'Operaciones_comercial'**: Será un número aleatorio entre 1,000 y 50,000.
- **'Operaciones_general'**: Será un número aleatorio entre 100 y 5,000.
- **'pasajeros_comercial'**: Será un número aleatorio entre 100,000 y 5,000,000.
- **'pasajeros_general'**: Será un número aleatorio entre 1000 y 15,000.

[ ]:
```
import pandas as pd
import numpy as np
from datetime import datetime

# Establecer una semilla para reproducibilidad
np.random.seed(42)

# Generar fechas de cierre de mes para un año específico
fechas = pd.date_range(start='2022-03-31', end='2024-03-31', freq='M')

# Crear nombres de aeropuertos
aeropuertos = [f'Aeropuerto_{i}' for i in range(1, 13)]

# Crear DataFrame con Datos Sintéticos
data = []
for fecha in fechas:
    for aeropuerto in aeropuertos:
```

```
        destinos_nacionales = np.random.randint(10, 30)
        destinos_internacionales = np.random.randint(1, 10)
        data.append({
            'fecha': fecha,
            'nombre_aeropuerto': aeropuerto,
            'tipo_aeropuerto': 'Internacional',
            'numero_aerolineas': np.random.randint(5, 20),
            'destinos_nacionales': destinos_nacionales,
            'destinos_internacionales': destinos_internacionales,
            'destinos_total': destinos_nacionales + destinos_internacionales,
            'Operaciones_comercial': np.random.randint(1000, 50000),
            'Operaciones_general': np.random.randint(100, 5000),
            'pasajeros_comercial': np.random.randint(100000, 5000000),
            'pasajeros_general': np.random.randint(100, 15000),
        })

df = pd.DataFrame(data)


# Diccionario de Nombres Reales de Aeropuertos
# Modificar diccionario cuando se tengan disponibles los nombres reales
nombres_aeropuertos = {
    'Aeropuerto_1': 'Primer_Aeropuerto',
    'Aeropuerto_2': 'Segundo_Aeropuerto',
    'Aeropuerto_3': 'Tercer_Aeropuerto',
    'Aeropuerto_4': 'Cuarto_Aeropuerto',
    'Aeropuerto_5': 'Quinto_Aeropuerto',
    'Aeropuerto_6': 'Sexto_Aeropuerto',
    'Aeropuerto_7': 'Séptimo_Aeropuerto',
    'Aeropuerto_8': 'Octavo_Aeropuerto',
    'Aeropuerto_9': 'Noveno_Aeropuerto',
    'Aeropuerto_10': 'Décimo_Aeropuerto',
    'Aeropuerto_11': 'Undécimo_Aeropuerto',
    'Aeropuerto_12': 'Duodécimo_Aeropuerto'
}

# Reemplazar los nombres genéricos por nombres reales en el DataFrame
df['nombre_aeropuerto'] = df['nombre_aeropuerto'].map(nombres_aeropuertos)

# Mostrar el DataFrame actualizado
df.head()
```

```
<ipython-input-2-fd6379722318>:9: FutureWarning: 'M' is deprecated and will be
removed in a future version, please use 'ME' instead.
  fechas = pd.date_range(start='2022-03-31', end='2024-03-31', freq='M')
```

[ ]:
```
        fecha   nombre_aeropuerto tipo_aeropuerto  numero_aerolineas  \
0 2022-03-31   Primer_Aeropuerto   Internacional                 17
1 2022-03-31  Segundo_Aeropuerto   Internacional                  9
2 2022-03-31   Tercer_Aeropuerto   Internacional                 16
3 2022-03-31   Cuarto_Aeropuerto   Internacional                  5
4 2022-03-31   Quinto_Aeropuerto   Internacional                 16

   destinos_nacionales  destinos_internacionales  destinos_total  \
0                   16                         4              20
1                   20                         8              28
2                   11                         8              19
3                   21                         9              30
4                   25                         3              28

   Operaciones_comercial  Operaciones_general  pasajeros_comercial  \
0                  39158                 3872              2334489
1                  45131                 3019              4572471
2                   3433                 1284              1496025
3                  42434                 1182              3630409
4                   2267                 1628              2528388

   pasajeros_general
0                566
1               8422
2              12409
3               2147
4               3990
```

[ ]:
```
# Asegurarse de que destinos_total es la suma de nacionales e internacionales
df['destinos_total'] = df['destinos_nacionales'] +␣
 ↪df['destinos_internacionales']
```

1.3.1 Exportar Datos Sintéticos

[ ]:
```
# Exportar a CSV
csv_file = 'datos_aeropuertos.csv'
df.to_csv(csv_file, index=False)
```

1.3.2 Carga de Datos

En esta sección se cargan los **datos "reales"** si ya están disponibles. De lo contrario, se cargan los **datos sintéticos** creados anteriormente.

[ ]:
```
# Datos reales
# Si ya se tiene el CSV con los datos reales, sólo hay que cargarlo

# Cargar el DataFrame desde un archivo CSV
```

```
#df_real = pd.read_csv('datos_aeropuertos.csv')
```

[ ]:
```
# Cargar Datos CSV a un DataFrame
df = pd.read_csv('datos_aeropuertos.csv')
df.head()
```

[ ]:

	fecha	nombre_aeropuerto	tipo_aeropuerto	numero_aerolineas	destinos_nacionales	destinos_internacionales	destinos_total	Operaciones_comercial	Operaciones_general	pasajeros_comercial	pasajeros_general
0	2022-03-31	Primer_Aeropuerto	Internacional	17	16	4	20	39158	3872	2334489	566
1	2022-03-31	Segundo_Aeropuerto	Internacional	9	20	8	28	45131	3019	4572471	8422
2	2022-03-31	Tercer_Aeropuerto	Internacional	16	11	8	19	3433	1284	1496025	12409
3	2022-03-31	Cuarto_Aeropuerto	Internacional	5	21	9	30	42434	1182	3630409	2147
4	2022-03-31	Quinto_Aeropuerto	Internacional	16	25	3	28	2267	1628	2528388	3990

[ ]:
```
# Asegurarse de que destinos_total es la suma de nacionales e internacionales
#df['destinos_total'] = df['destinos_nacionales'] +␣
 ↪df['destinos_internacionales']
```

1.3.3 Información

[ ]:
```
# Filas y Columnas
print("Cantidad de Filas y Columnas en el DataFrame")
df.shape
```

```
Cantidad de Filas y Columnas en el DataFrame
```

[ ]:
```
(300, 11)
```

[ ]:
```
# Info General
print("Información de Variables, Cantidad de Registros No Nulos, y Tipos de Datos")
df.info()
```

```
Información de Variables, Cantidad de Registros No Nulos, y Tipos de Datos
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 300 entries, 0 to 299
Data columns (total 11 columns):
 #   Column                     Non-Null Count  Dtype
---  ------                     --------------  -----
 0   fecha                      300 non-null    object
 1   nombre_aeropuerto          300 non-null    object
 2   tipo_aeropuerto            300 non-null    object
 3   numero_aerolineas          300 non-null    int64
 4   destinos_nacionales        300 non-null    int64
 5   destinos_internacionales   300 non-null    int64
 6   destinos_total             300 non-null    int64
 7   Operaciones_comercial      300 non-null    int64
 8   Operaciones_general        300 non-null    int64
 9   pasajeros_comercial        300 non-null    int64
 10  pasajeros_general          300 non-null    int64
dtypes: int64(8), object(3)
memory usage: 25.9+ KB
```

[ ]:
```
# Variables (Columnas)
print("Nombres de las Variables (Columnas)")
df.columns
```

```
Nombres de las Variables (Columnas)
```

[ ]:
```
Index(['fecha', 'nombre_aeropuerto', 'tipo_aeropuerto', 'numero_aerolineas',
       'destinos_nacionales', 'destinos_internacionales', 'destinos_total',
       'Operaciones_comercial', 'Operaciones_general', 'pasajeros_comercial',
       'pasajeros_general'],
      dtype='object')
```

1.4 Análisis Exploratorio de Datos (EDA) Básico

[ ]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Asegúrate de que matplotlib muestre los gráficos
%matplotlib inline

# Se sigue usando el mismo df previo
```

```
# Visualización de las primeras filas del conjunto de datos
print("Primeras filas del conjunto de datos:")
df.head()
```

```
Primeras filas del conjunto de datos:
```

[ ]:
```
        fecha   nombre_aeropuerto tipo_aeropuerto  numero_aerolineas  \
0  2022-03-31   Primer_Aeropuerto   Internacional                 17
1  2022-03-31  Segundo_Aeropuerto   Internacional                  9
2  2022-03-31   Tercer_Aeropuerto   Internacional                 16
3  2022-03-31   Cuarto_Aeropuerto   Internacional                  5
4  2022-03-31   Quinto_Aeropuerto   Internacional                 16

   destinos_nacionales  destinos_internacionales  destinos_total  \
0                   16                         4              20
1                   20                         8              28
2                   11                         8              19
3                   21                         9              30
4                   25                         3              28

   Operaciones_comercial  Operaciones_general  pasajeros_comercial  \
0                  39158                 3872              2334489
1                  45131                 3019              4572471
2                   3433                 1284              1496025
3                  42434                 1182              3630409
4                   2267                 1628              2528388

   pasajeros_general
0                566
1               8422
2              12409
3               2147
4               3990
```

1.4.1 Estadísticas

[ ]:
```
# Resumen estadístico de las columnas numéricas
print("\nResumen estadístico del conjunto de datos:")
df.describe()
```

```
Resumen estadístico del conjunto de datos:
```

[ ]:
```
       numero_aerolineas  destinos_nacionales  destinos_internacionales  \
count         300.000000           300.000000                300.000000
mean           12.013333            19.816667                  4.960000
```

```
std              4.480335             5.834655                  2.576924
min              5.000000            10.000000                  1.000000
25%              8.000000            15.000000                  3.000000
50%             12.000000            20.500000                  5.000000
75%             16.000000            25.000000                  7.000000
max             19.000000            29.000000                  9.000000

       destinos_total  Operaciones_comercial  Operaciones_general  \
count      300.000000             300.000000           300.000000
mean        24.776667           24804.473333          2487.136667
std          6.322978           14526.371602          1412.868771
min         12.000000            1060.000000           102.000000
25%         19.000000           11989.750000          1132.750000
50%         25.000000           24666.500000          2598.500000
75%         30.000000           37977.000000          3655.000000
max         38.000000           49988.000000          4995.000000

       pasajeros_comercial  pasajeros_general
count         3.000000e+02         300.000000
mean          2.616075e+06        7347.833333
std           1.418837e+06        4172.858786
min           1.004040e+05         101.000000
25%           1.324220e+06        3722.250000
50%           2.625982e+06        7229.000000
75%           3.858899e+06       10937.750000
max           4.997954e+06       14890.000000
```

1.4.2 Barplot

Operaciones Comerciales

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Asegúrate de que la columna fecha es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month' si no existe

# Configuración de Seaborn
sns.set(style="white")

# Configurar una paleta de colores
palette = sns.color_palette("crest", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Preparar los datos para Seaborn FacetGrid
```

```
operaciones_comerciales_long = df[['nombre_aeropuerto', 'year_month',␣
 ↪'Operaciones_comercial']]

# Crear el FacetGrid
g = sns.FacetGrid(operaciones_comerciales_long, col='year_month', col_wrap=4,␣
 ↪height=3, aspect=1.5)
g.map_dataframe(sns.barplot, x='nombre_aeropuerto', y='Operaciones_comercial',␣
 ↪hue='nombre_aeropuerto', palette=palette, order=df['nombre_aeropuerto'].
 ↪unique(), legend=False)

# Ajustar propiedades de las barras después de crearlas
for ax in g.axes.flat:
    for bar in ax.patches:
        bar.set_edgecolor('black')  # Ajustar el color de borde
        bar.set_alpha(0.7)  # Ajustar la transparencia

# Ajustar títulos y etiquetas
g.set_titles('{col_name}')
g.set_axis_labels('Aeropuerto', 'Operaciones Comerciales')
for ax in g.axes.flatten():
    for label in ax.get_xticklabels():
        label.set_rotation(45)

# Ajustar espacio entre gráficos para evitar solapamiento
plt.subplots_adjust(hspace=0.4, wspace=0.4)

# Añadir un título general sobre todos los subgráficos
plt.subplots_adjust(top=0.9)
g.fig.suptitle('Operaciones Comerciales en Aeropuertos Vistos en Subgráficos␣
 ↪Mensuales', fontsize=16)

# Mostrar el gráfico
plt.show()
```

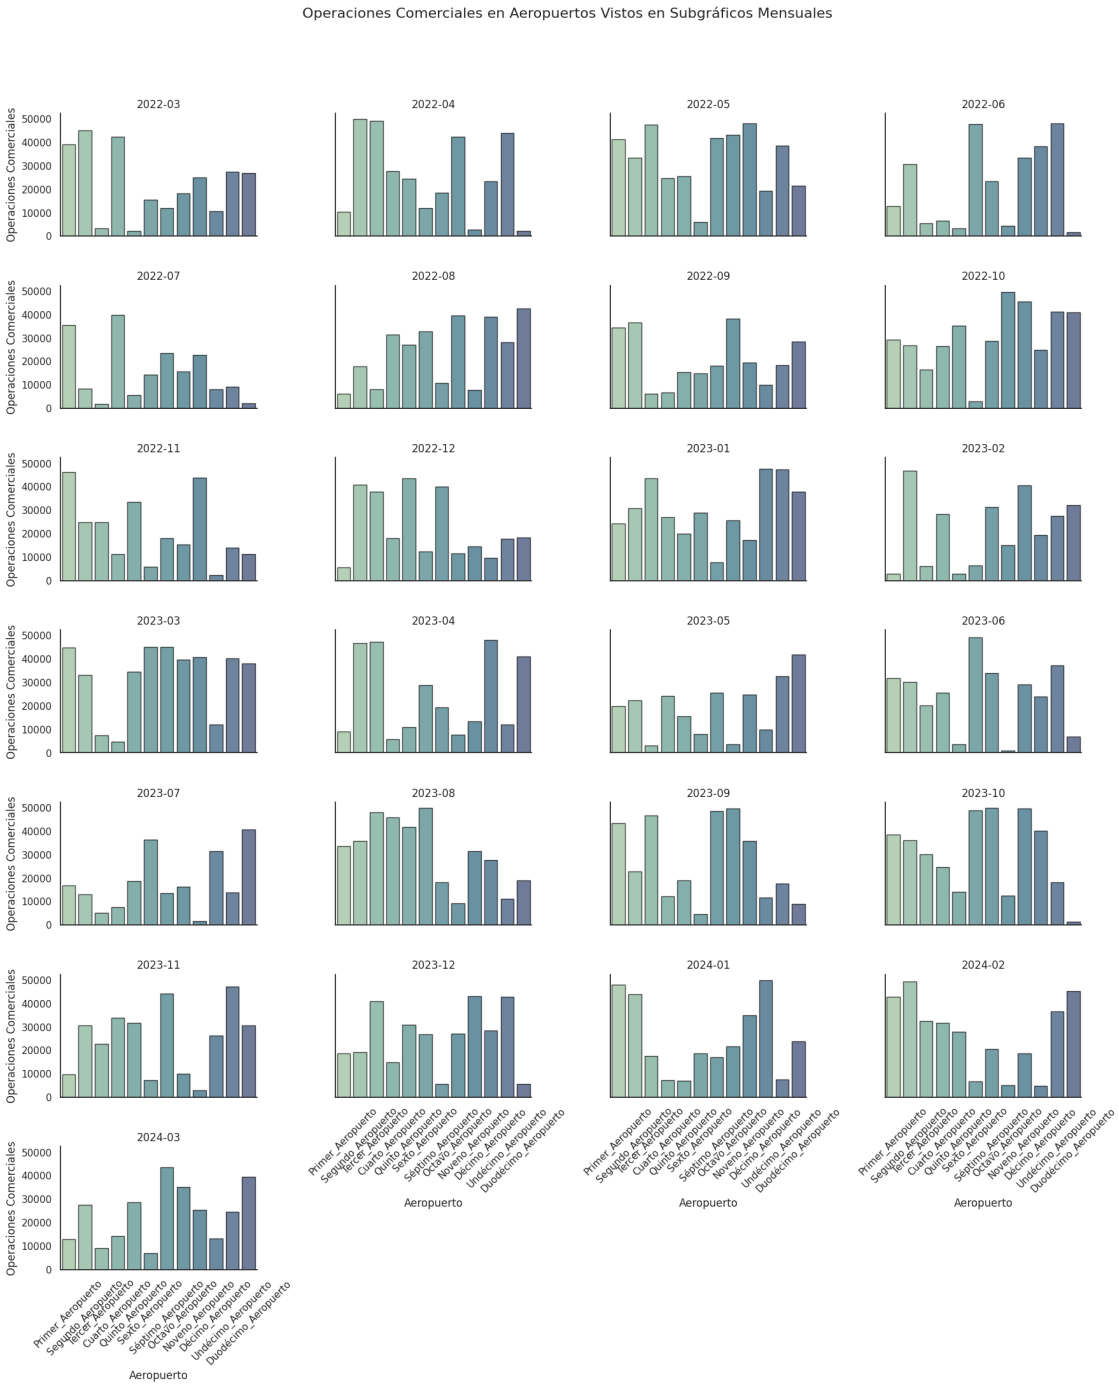

Pasajeros Comerciales

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
```

```
# Asegúrate de que la columna fecha es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month' si no existe

# Configuración de Seaborn
sns.set(style="white")

# Configurar una paleta de colores
palette = sns.color_palette("magma", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Preparar los datos para Seaborn FacetGrid
operaciones_comerciales_long = df[['nombre_aeropuerto', 'year_month',␣
 ↪'pasajeros_comercial']]

# Crear el FacetGrid
g = sns.FacetGrid(operaciones_comerciales_long, col='year_month', col_wrap=4,␣
 ↪height=3, aspect=1.5)
g.map_dataframe(sns.barplot, x='nombre_aeropuerto', y='pasajeros_comercial',␣
 ↪hue='nombre_aeropuerto', palette=palette, order=df['nombre_aeropuerto'].
 ↪unique(), legend=False)

# Ajustar propiedades de las barras después de crearlas
for ax in g.axes.flat:
    for bar in ax.patches:
        bar.set_edgecolor('black')  # Ajustar el color de borde
        bar.set_alpha(0.7)  # Ajustar la transparencia

# Ajustar títulos y etiquetas
g.set_titles('{col_name}')
g.set_axis_labels('Aeropuerto', 'Pasajeros Comerciales')
for ax in g.axes.flatten():
    for label in ax.get_xticklabels():
        label.set_rotation(45)

# Ajustar espacio entre gráficos para evitar solapamiento
plt.subplots_adjust(hspace=0.4, wspace=0.4)

# Añadir un título general sobre todos los subgráficos
plt.subplots_adjust(top=0.9)
g.fig.suptitle('Pasajeros Comerciales en Aeropuertos Vistos en Subgráficos␣
 ↪Mensuales', fontsize=16)

# Mostrar el gráfico
plt.show()
```

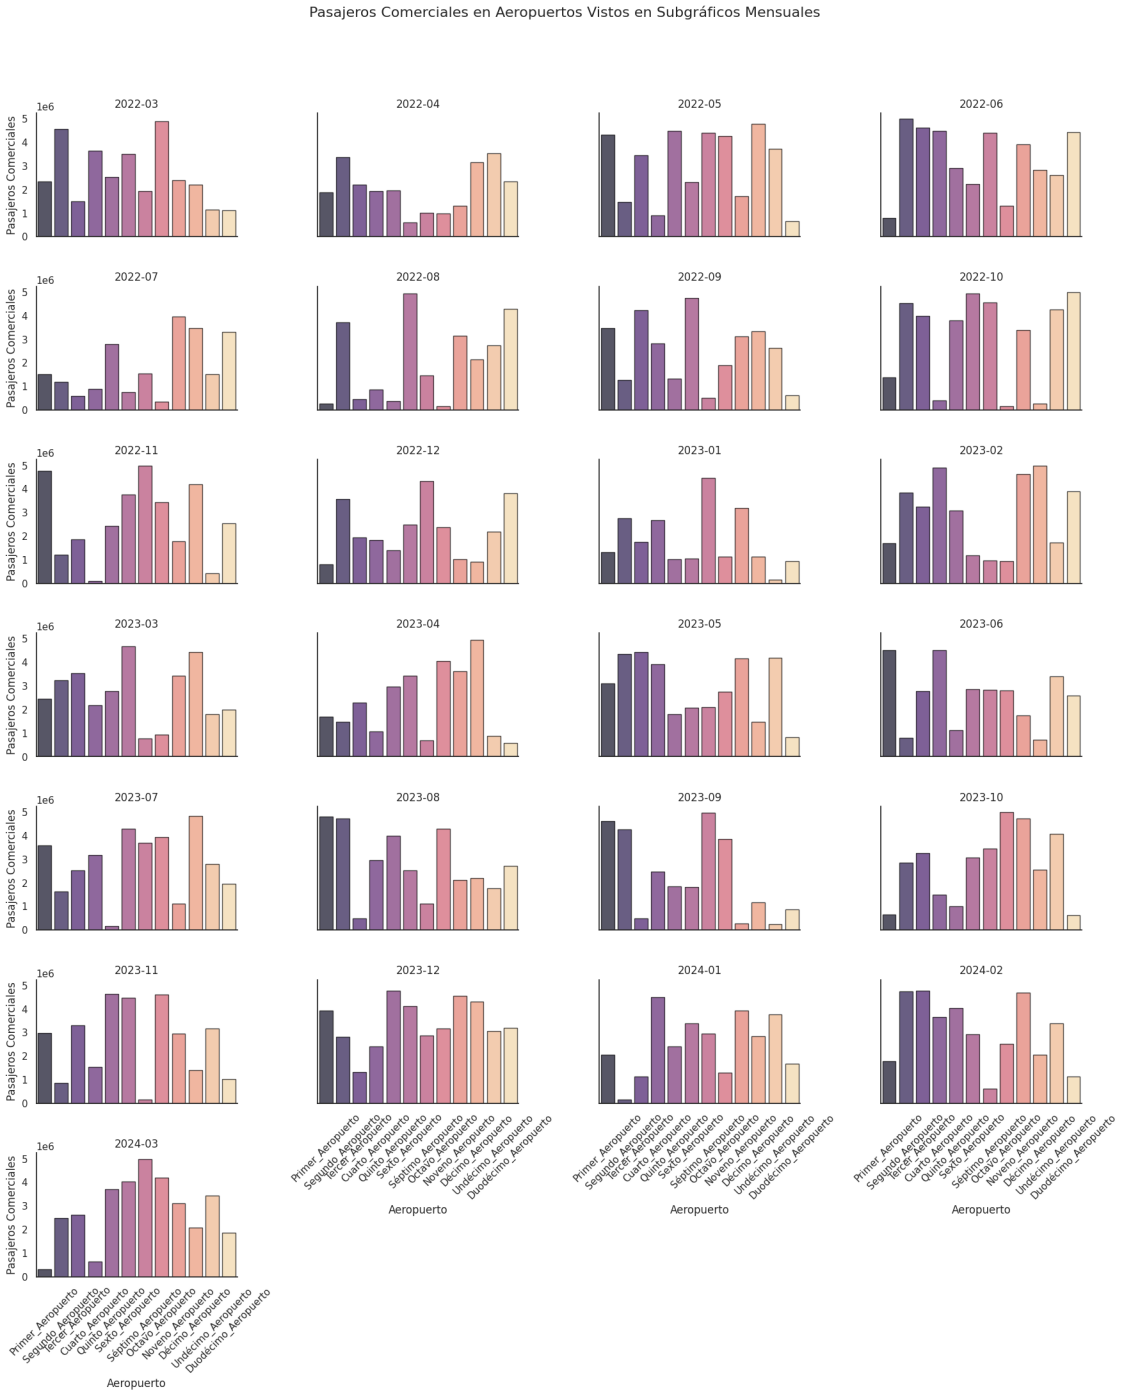

1.4.3 Lineplot

Operaciones Comerciales

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
```

```
import pandas as pd

# Asegurarse de que la columna fecha es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month' si no existe

# Configuración de Seaborn
sns.set(style="white")  # Cambiado a "whitegrid" para mejor visualización de␣
 ↪las líneas

# Configurar una paleta de colores
palette = sns.color_palette("crest", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Crear el FacetGrid, cada columna es un aeropuerto
g = sns.FacetGrid(df, col='nombre_aeropuerto', col_wrap=4, height=3, aspect=1.5)

# Mapear un lineplot para cada subgráfico del grid
g.map_dataframe(sns.lineplot, x='year_month', y='Operaciones_comercial',␣
 ↪color='#f7a541')

# Ajustar títulos y etiquetas
g.set_titles('{col_name}')
g.set_axis_labels('Fecha', 'Operaciones Comerciales')
for ax in g.axes.flatten():
    ax.tick_params(labelrotation=45)  # Rotar etiquetas del eje X para mejor␣
 ↪visualización

# Ajustar espacio entre gráficos para evitar solapamiento
plt.subplots_adjust(hspace=0.4, wspace=0.4)

# Añadir un título general sobre todos los subgráficos
plt.subplots_adjust(top=0.9)
g.fig.suptitle('Tendencia de Operaciones Comerciales en Subgráficos por␣
 ↪Aeropuerto', fontsize=16)

# Mostrar el gráfico
plt.show()
```

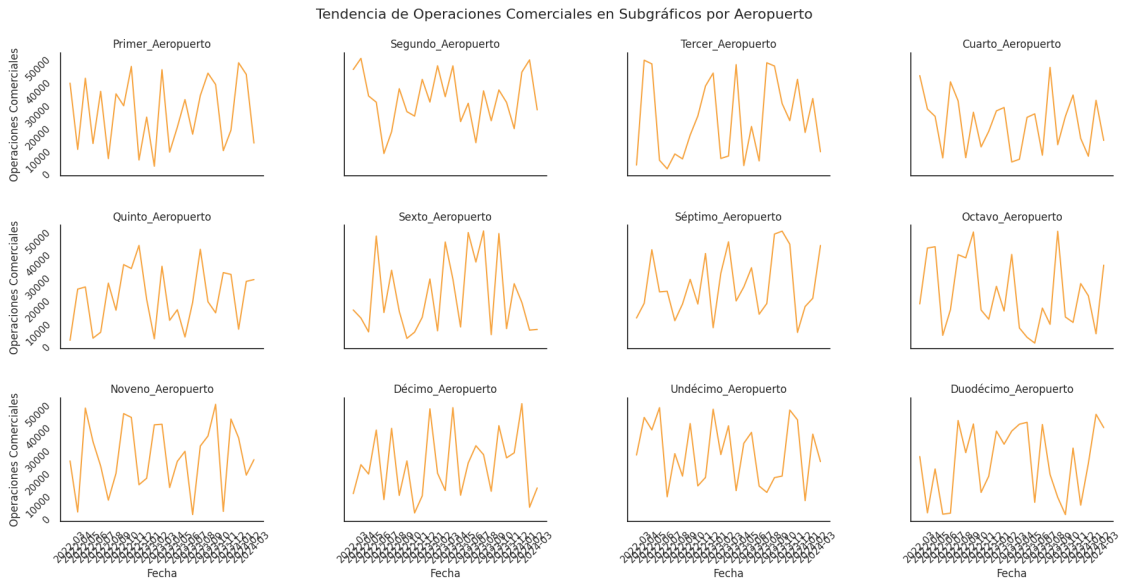

Pasajeros Comercial

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Asegurarse de que la columna fecha es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month' si no existe

# Configuración de Seaborn
sns.set(style="white")

# Configurar una paleta de colores
palette = sns.color_palette("crest", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Crear el FacetGrid, cada columna es un aeropuerto
g = sns.FacetGrid(df, col='nombre_aeropuerto', col_wrap=4, height=3, aspect=1.5)

# Mapear un lineplot para cada subgráfico del grid
g.map_dataframe(sns.lineplot, x='year_month', y='pasajeros_comercial',␣
 ↪color='#31b2f2')

# Ajustar títulos y etiquetas
g.set_titles('{col_name}')
g.set_axis_labels('Fecha', 'Pasajeros Comerciales')
```

```
for ax in g.axes.flatten():
    ax.tick_params(labelrotation=45)  # Rotar etiquetas del eje X para mejor␣
 ↪visualización

# Ajustar espacio entre gráficos para evitar solapamiento
plt.subplots_adjust(hspace=0.4, wspace=0.4)

# Añadir un título general sobre todos los subgráficos
plt.subplots_adjust(top=0.9)
g.fig.suptitle('Tendencia de Pasajeros Comerciales en Subgráficos por␣
 ↪Aeropuerto', fontsize=16)

# Mostrar el gráfico
plt.show()
```

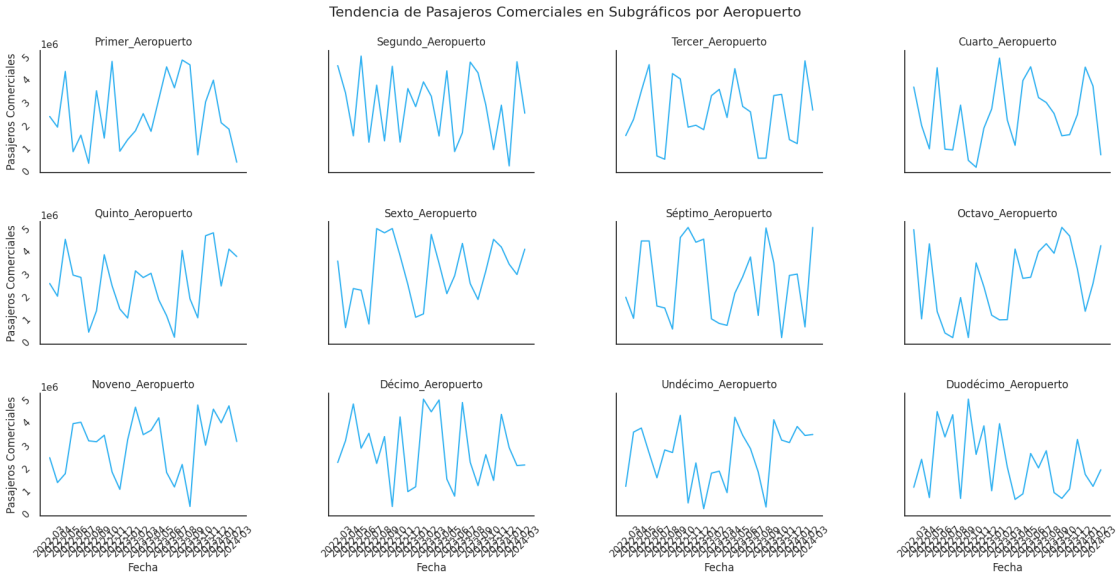

1.4.4 Boxplot

Operaciones Comerciales

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Asegúrate de que la columna 'fecha' es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month'
```

```
# Configuración de Seaborn
sns.set(style="white")

# Seleccionar una paleta de colores
palette = sns.color_palette("mako", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Crear un boxplot de Operaciones Comerciales para cada aeropuerto
plt.figure(figsize=(12, 6))  # Configurar el tamaño de la figura

# Crear el boxplot usando la paleta de colores seleccionada
sns.boxplot(x='nombre_aeropuerto', y='Operaciones_comercial', data=df,␣
 ↪hue='nombre_aeropuerto', palette=palette)

# Ajustar detalles del gráfico
plt.title('Distribución de Operaciones Comerciales por Aeropuerto', fontsize=14)
plt.xlabel('Aeropuerto', fontsize=12)  # Ajustar el tamaño de la etiqueta del␣
 ↪eje X
plt.ylabel('Operaciones Comerciales', fontsize=12)  # Ajustar el tamaño de la␣
 ↪etiqueta del eje Y
plt.xticks(rotation=45)  # Rotar las etiquetas del eje X para mejor legibilidad
plt.tick_params(axis='x', labelsize=10)  # Ajustar el tamaño de las etiquetas␣
 ↪de los ticks del eje X
plt.tick_params(axis='y', labelsize=10)  # Ajustar el tamaño de las etiquetas␣
 ↪de los ticks del eje Y

# Mostrar el gráfico
plt.show()
```

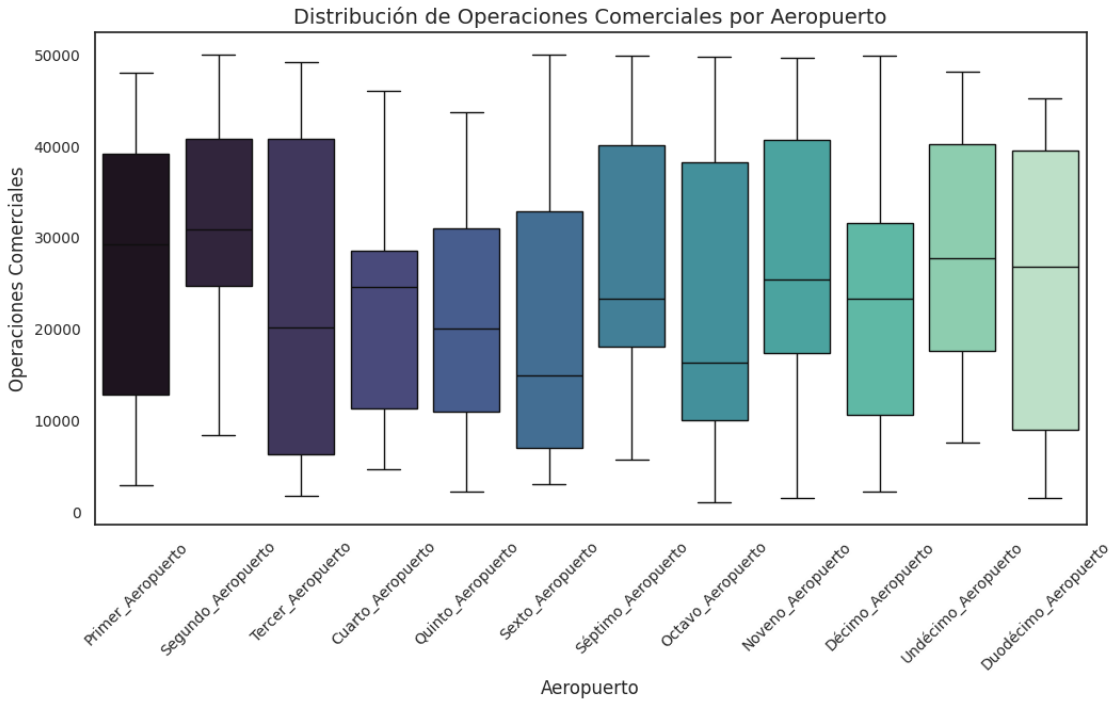

1.4.5 Outliers

Operaciones Comerciales

[ ]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Asegúrate de que la columna 'fecha' es tipo datetime si no lo es
df['fecha'] = pd.to_datetime(df['fecha'])
df['year_month'] = df['fecha'].dt.strftime('%Y-%m')  # Crear columna␣
 ↪'year_month'

# Configuración de Seaborn
sns.set(style="white")

# Seleccionar una paleta de colores
palette = sns.color_palette("magma", n_colors=len(df['nombre_aeropuerto'].
 ↪unique()))

# Crear un boxplot de Operaciones Comerciales para cada aeropuerto
plt.figure(figsize=(12, 6))  # Configurar el tamaño de la figura

# Crear el boxplot usando la paleta de colores seleccionada
```

```
ax = sns.boxplot(x='nombre_aeropuerto', y='Operaciones_comercial', data=df,␣
 ↪hue='nombre_aeropuerto', palette=palette, showfliers=True)

# Añadir stripplot para mostrar todos los puntos de datos
sns.stripplot(x='nombre_aeropuerto', y='Operaciones_comercial', data=df,␣
 ↪color='black', size=3, jitter=True, alpha=0.5)

# Ajustar detalles del gráfico
plt.title('Distribución de Operaciones Comerciales por Aeropuerto', fontsize=14)
plt.xlabel('Aeropuerto', fontsize=12)  # Ajustar el tamaño de la etiqueta del␣
 ↪eje X
plt.ylabel('Operaciones Comerciales', fontsize=12)  # Ajustar el tamaño de la␣
 ↪etiqueta del eje Y
plt.xticks(rotation=45)  # Rotar las etiquetas del eje X para mejor legibilidad
plt.tick_params(axis='x', labelsize=10)  # Ajustar el tamaño de las etiquetas␣
 ↪de los ticks del eje X
plt.tick_params(axis='y', labelsize=10)  # Ajustar el tamaño de las etiquetas␣
 ↪de los ticks del eje Y

# Mostrar el gráfico
plt.show()
```

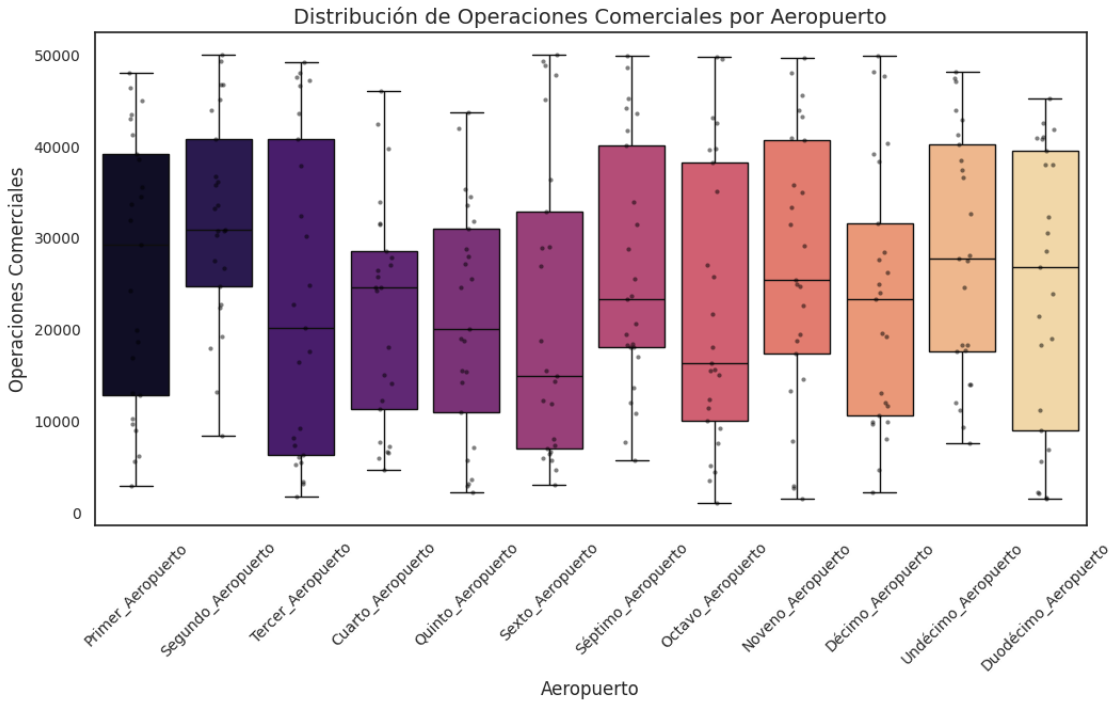

1.5 Modelo

1.5.1 Definición del Modelo

[ ]:
```
# Definición del Modelo

# Importar
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler, LabelEncoder
from sklearn.model_selection import train_test_split
from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, Dense, Dropout
from tensorflow.keras.optimizers import Adam

# Asegurarse de que la columna fecha es tipo datetime
df['fecha'] = pd.to_datetime(df['fecha'])

# Convertir 'fecha' en componentes numéricos
df['year'] = df['fecha'].dt.year
df['month'] = df['fecha'].dt.month

# Codificar variables categóricas
le = LabelEncoder()
df['nombre_aeropuerto_encoded'] = le.fit_transform(df['nombre_aeropuerto'])

# Normalizar los datos - Crear dos scalers
scaler_X = MinMaxScaler()
scaler_y = MinMaxScaler()

features = ['year', 'month', 'nombre_aeropuerto_encoded']
df[features] = scaler_X.fit_transform(df[features])

# Preparar características y etiquetas
X = df[features]
y = df[['numero_aerolineas', 'destinos_nacionales', 'destinos_internacionales',␣
 ↪'Operaciones_comercial', 'Operaciones_general', 'pasajeros_comercial',␣
 ↪'pasajeros_general']]
y = scaler_y.fit_transform(y)  # Normalizar salidas usando un scaler diferente

# Dividir los datos
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=42)

# Construcción del modelo
inputs = Input(shape=(X_train.shape[1],))
x = Dense(64, activation='relu')(inputs)
x = Dropout(0.5)(x)
```

```
x = Dense(64, activation='relu')(x)
outputs = Dense(y_train.shape[1], activation='linear')(x)  # Usar 'linear'␣
 ↪porque las salidas están normalizadas

model = Model(inputs, outputs)
```

1.5.2 Resumen del Modelo

[ ]:
```
# Resumen del Modelo
model.summary()
```

```
Model: "functional"
```

Layer (type)	Output Shape	Param #
input_layer (InputLayer)	(None, 3)	0
dense (Dense)	(None, 64)	256
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 64)	4,160
dense_2 (Dense)	(None, 7)	455

```
Total params: 4,871 (19.03 KB)

Trainable params: 4,871 (19.03 KB)

Non-trainable params: 0 (0.00 B)
```

1.5.3 Compilar el Modelo

[ ]:
```
# Compilar el modelo
model.compile(optimizer=Adam(learning_rate=0.01), loss='mse')
```

1.5.4 Entrenar el Modelo

[ ]:
```
# Entrenar el modelo y guardar el historial
history = model.fit(X_train, y_train, epochs=100, batch_size=32,␣
↪validation_split=0.1)
```

```
Epoch 1/100
7/7             4s 185ms/step - loss:
0.2631 - val_loss: 0.1159
Epoch 2/100
7/7             2s 5ms/step - loss:
0.1221 - val_loss: 0.0910
Epoch 3/100
7/7             0s 5ms/step - loss:
0.1068 - val_loss: 0.0928
Epoch 4/100
7/7             0s 5ms/step - loss:
0.0991 - val_loss: 0.0883
Epoch 5/100
7/7             0s 6ms/step - loss:
0.0947 - val_loss: 0.0884
Epoch 6/100
7/7             0s 5ms/step - loss:
0.0931 - val_loss: 0.0888
Epoch 7/100
7/7             0s 5ms/step - loss:
0.0926 - val_loss: 0.0894
Epoch 8/100
7/7             0s 5ms/step - loss:
0.0947 - val_loss: 0.0905
Epoch 9/100
7/7             0s 5ms/step - loss:
0.0908 - val_loss: 0.0893
Epoch 10/100
7/7             0s 5ms/step - loss:
0.0926 - val_loss: 0.0894
Epoch 11/100
7/7             0s 5ms/step - loss:
0.0910 - val_loss: 0.0917
Epoch 12/100
7/7             0s 6ms/step - loss:
0.0914 - val_loss: 0.0889
Epoch 13/100
```

```
7/7            0s 6ms/step - loss:
0.0890 - val_loss: 0.0885
Epoch 14/100
7/7            0s 6ms/step - loss:
0.0908 - val_loss: 0.0901
Epoch 15/100
7/7            0s 5ms/step - loss:
0.0918 - val_loss: 0.0895
Epoch 16/100
7/7            0s 5ms/step - loss:
0.0892 - val_loss: 0.0895
Epoch 17/100
7/7            0s 5ms/step - loss:
0.0923 - val_loss: 0.0894
Epoch 18/100
7/7            0s 5ms/step - loss:
0.0901 - val_loss: 0.0907
Epoch 19/100
7/7            0s 5ms/step - loss:
0.0925 - val_loss: 0.0913
Epoch 20/100
7/7            0s 5ms/step - loss:
0.0909 - val_loss: 0.0896
Epoch 21/100
7/7            0s 5ms/step - loss:
0.0902 - val_loss: 0.0899
Epoch 22/100
7/7            0s 5ms/step - loss:
0.0913 - val_loss: 0.0910
Epoch 23/100
7/7            0s 8ms/step - loss:
0.0905 - val_loss: 0.0917
Epoch 24/100
7/7            0s 5ms/step - loss:
0.0893 - val_loss: 0.0906
Epoch 25/100
7/7            0s 5ms/step - loss:
0.0896 - val_loss: 0.0919
Epoch 26/100
7/7            0s 5ms/step - loss:
0.0892 - val_loss: 0.0926
Epoch 27/100
7/7            0s 5ms/step - loss:
0.0884 - val_loss: 0.0918
Epoch 28/100
7/7            0s 5ms/step - loss:
0.0900 - val_loss: 0.0914
Epoch 29/100
```

```
7/7            0s 6ms/step - loss:
0.0876 - val_loss: 0.0917
Epoch 30/100
7/7            0s 6ms/step - loss:
0.0862 - val_loss: 0.0920
Epoch 31/100
7/7            0s 6ms/step - loss:
0.0890 - val_loss: 0.0903
Epoch 32/100
7/7            0s 6ms/step - loss:
0.0894 - val_loss: 0.0907
Epoch 33/100
7/7            0s 5ms/step - loss:
0.0902 - val_loss: 0.0902
Epoch 34/100
7/7            0s 5ms/step - loss:
0.0897 - val_loss: 0.0901
Epoch 35/100
7/7            0s 5ms/step - loss:
0.0904 - val_loss: 0.0909
Epoch 36/100
7/7            0s 5ms/step - loss:
0.0893 - val_loss: 0.0926
Epoch 37/100
7/7            0s 5ms/step - loss:
0.0880 - val_loss: 0.0896
Epoch 38/100
7/7            0s 5ms/step - loss:
0.0926 - val_loss: 0.0907
Epoch 39/100
7/7            0s 5ms/step - loss:
0.0881 - val_loss: 0.0892
Epoch 40/100
7/7            0s 6ms/step - loss:
0.0896 - val_loss: 0.0906
Epoch 41/100
7/7            0s 5ms/step - loss:
0.0896 - val_loss: 0.0900
Epoch 42/100
7/7            0s 5ms/step - loss:
0.0882 - val_loss: 0.0902
Epoch 43/100
7/7            0s 5ms/step - loss:
0.0887 - val_loss: 0.0900
Epoch 44/100
7/7            0s 5ms/step - loss:
0.0896 - val_loss: 0.0889
Epoch 45/100
```

```
7/7            0s 5ms/step - loss:
0.0868 - val_loss: 0.0895
Epoch 46/100
7/7            0s 6ms/step - loss:
0.0874 - val_loss: 0.0898
Epoch 47/100
7/7            0s 6ms/step - loss:
0.0839 - val_loss: 0.0894
Epoch 48/100
7/7            0s 6ms/step - loss:
0.0877 - val_loss: 0.0911
Epoch 49/100
7/7            0s 6ms/step - loss:
0.0868 - val_loss: 0.0912
Epoch 50/100
7/7            0s 5ms/step - loss:
0.0878 - val_loss: 0.0904
Epoch 51/100
7/7            0s 5ms/step - loss:
0.0869 - val_loss: 0.0904
Epoch 52/100
7/7            0s 10ms/step - loss:
0.0886 - val_loss: 0.0910
Epoch 53/100
7/7            0s 7ms/step - loss:
0.0899 - val_loss: 0.0900
Epoch 54/100
7/7            0s 9ms/step - loss:
0.0888 - val_loss: 0.0911
Epoch 55/100
7/7            0s 7ms/step - loss:
0.0883 - val_loss: 0.0906
Epoch 56/100
7/7            0s 7ms/step - loss:
0.0914 - val_loss: 0.0909
Epoch 57/100
7/7            0s 9ms/step - loss:
0.0873 - val_loss: 0.0912
Epoch 58/100
7/7            0s 10ms/step - loss:
0.0873 - val_loss: 0.0909
Epoch 59/100
7/7            0s 7ms/step - loss:
0.0894 - val_loss: 0.0921
Epoch 60/100
7/7            0s 7ms/step - loss:
0.0873 - val_loss: 0.0907
Epoch 61/100
```

```
7/7            0s 8ms/step - loss:
0.0862 - val_loss: 0.0910
Epoch 62/100
7/7            0s 10ms/step - loss:
0.0894 - val_loss: 0.0926
Epoch 63/100
7/7            0s 7ms/step - loss:
0.0870 - val_loss: 0.0918
Epoch 64/100
7/7            0s 7ms/step - loss:
0.0877 - val_loss: 0.0918
Epoch 65/100
7/7            0s 7ms/step - loss:
0.0881 - val_loss: 0.0904
Epoch 66/100
7/7            0s 8ms/step - loss:
0.0889 - val_loss: 0.0928
Epoch 67/100
7/7            0s 7ms/step - loss:
0.0896 - val_loss: 0.0900
Epoch 68/100
7/7            0s 11ms/step - loss:
0.0881 - val_loss: 0.0924
Epoch 69/100
7/7            0s 5ms/step - loss:
0.0876 - val_loss: 0.0912
Epoch 70/100
7/7            0s 5ms/step - loss:
0.0891 - val_loss: 0.0923
Epoch 71/100
7/7            0s 5ms/step - loss:
0.0888 - val_loss: 0.0913
Epoch 72/100
7/7            0s 5ms/step - loss:
0.0872 - val_loss: 0.0913
Epoch 73/100
7/7            0s 5ms/step - loss:
0.0896 - val_loss: 0.0931
Epoch 74/100
7/7            0s 6ms/step - loss:
0.0890 - val_loss: 0.0928
Epoch 75/100
7/7            0s 5ms/step - loss:
0.0879 - val_loss: 0.0899
Epoch 76/100
7/7            0s 5ms/step - loss:
0.0876 - val_loss: 0.0908
Epoch 77/100
```

```
7/7            0s 5ms/step - loss:
0.0881 - val_loss: 0.0914
Epoch 78/100
7/7            0s 7ms/step - loss:
0.0882 - val_loss: 0.0916
Epoch 79/100
7/7            0s 6ms/step - loss:
0.0878 - val_loss: 0.0919
Epoch 80/100
7/7            0s 5ms/step - loss:
0.0881 - val_loss: 0.0915
Epoch 81/100
7/7            0s 5ms/step - loss:
0.0866 - val_loss: 0.0914
Epoch 82/100
7/7            0s 5ms/step - loss:
0.0900 - val_loss: 0.0916
Epoch 83/100
7/7            0s 5ms/step - loss:
0.0877 - val_loss: 0.0916
Epoch 84/100
7/7            0s 5ms/step - loss:
0.0867 - val_loss: 0.0910
Epoch 85/100
7/7            0s 5ms/step - loss:
0.0878 - val_loss: 0.0928
Epoch 86/100
7/7            0s 5ms/step - loss:
0.0911 - val_loss: 0.0916
Epoch 87/100
7/7            0s 5ms/step - loss:
0.0869 - val_loss: 0.0914
Epoch 88/100
7/7            0s 5ms/step - loss:
0.0895 - val_loss: 0.0915
Epoch 89/100
7/7            0s 5ms/step - loss:
0.0891 - val_loss: 0.0909
Epoch 90/100
7/7            0s 8ms/step - loss:
0.0899 - val_loss: 0.0930
Epoch 91/100
7/7            0s 5ms/step - loss:
0.0882 - val_loss: 0.0899
Epoch 92/100
7/7            0s 5ms/step - loss:
0.0882 - val_loss: 0.0911
Epoch 93/100
```

```
7/7             0s 5ms/step - loss:
0.0871 - val_loss: 0.0919
Epoch 94/100
7/7             0s 6ms/step - loss:
0.0870 - val_loss: 0.0931
Epoch 95/100
7/7             0s 6ms/step - loss:
0.0856 - val_loss: 0.0915
Epoch 96/100
7/7             0s 5ms/step - loss:
0.0901 - val_loss: 0.0897
Epoch 97/100
7/7             0s 5ms/step - loss:
0.0895 - val_loss: 0.0919
Epoch 98/100
7/7             0s 5ms/step - loss:
0.0898 - val_loss: 0.0904
Epoch 99/100
7/7             0s 5ms/step - loss:
0.0860 - val_loss: 0.0916
Epoch 100/100
7/7             0s 5ms/step - loss:
0.0875 - val_loss: 0.0923
```

1.5.5 Evaluar el Modelo

[ ]:
```python
# Evaluación del modelo
loss = model.evaluate(X_test, y_test)
print(f"Loss en el conjunto de prueba: {loss}")
```

```
2/2             0s 219ms/step - loss:
0.0911
Loss en el conjunto de prueba: 0.09049880504608154
```

1.5.6 Visualizar Historial de Pérdidas

[ ]:
```python
# Visualizar Historial de Pérdidas
import matplotlib.pyplot as plt
import seaborn as sns

# Configurar Seaborn
sns.set(style="white")

# Lineplot del Histórico de Pérdidas de Entrenamiento y Validación
epochs = range(1, len(history.history['loss']) + 1)
plt.figure(figsize=(8, 6))
plt.plot(epochs, history.history['loss'], label='Train Loss', color='#023685')
```

```
plt.plot(epochs, history.history['val_loss'], label='Validation Loss',␣
 ↪color='#00B0F0')
plt.title('Histórico de Pérdidas de Entrenamiento y Validación', fontsize=11)
plt.xlabel('Épocas (Epochs)', fontsize=11)
plt.ylabel('Pérdida (Loss)', fontsize=11)
plt.legend()
plt.show()
```

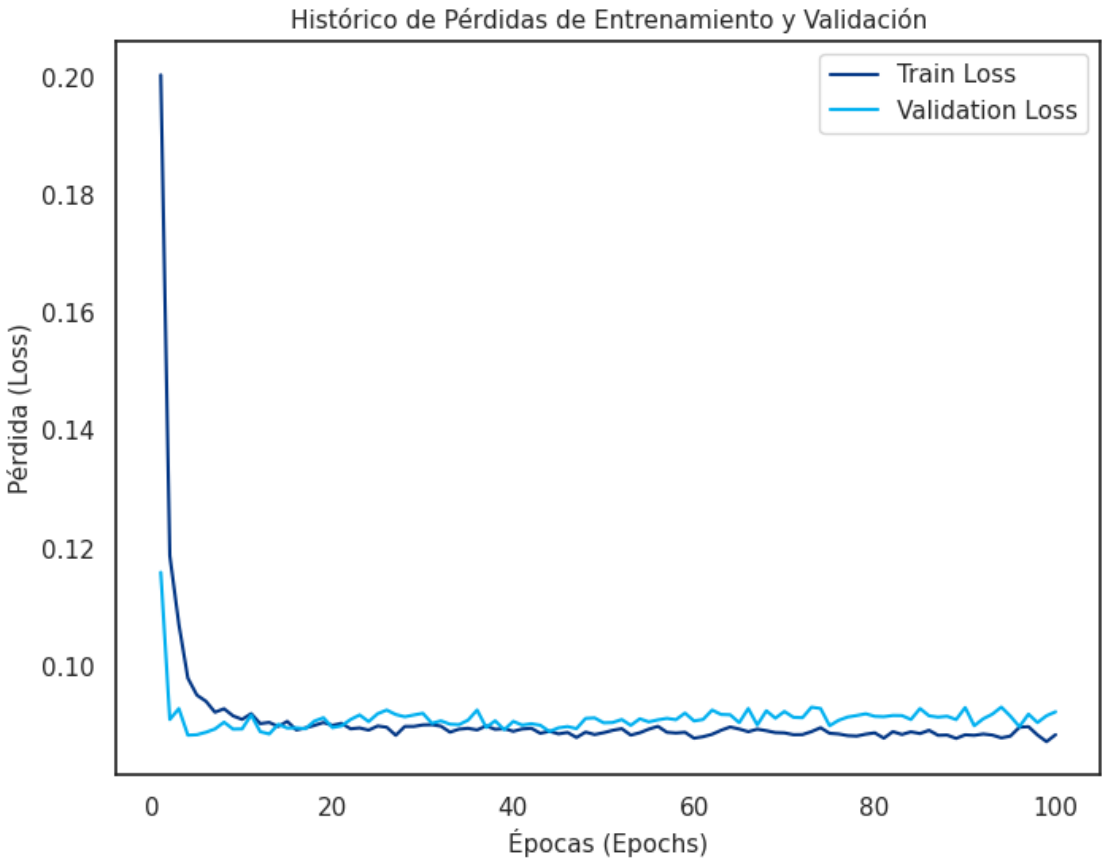

1.6 Evaluación del Modelo (Test)

1.6.1 Métricas de Evaluación: MAE, RMSE, R-squared

Este código calculará métricas de evaluación (sobre el conjunto Test) siguientes:

1. **MAE (Error Absoluto Medio)**: Representa el promedio de las diferencias absolutas entre las predicciones y los valores reales. Es una métrica fácil de interpretar, donde un valor más bajo indica un mejor rendimiento del modelo.
2. **RMSE (Raíz del Error Cuadrático Medio)**: Mide la raíz cuadrada del promedio de los errores cuadrados entre las predicciones y los valores reales. Penaliza los errores grandes más que el MAE.

3. **R-squared (R-cuadrada)**: Indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes. Un valor más cercano a 1 indica un mejor ajuste del modelo.

[ ]:
```python
# Importar
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
import numpy as np

# Generar predicciones del modelo sobre los datos de prueba
y_pred_test = model.predict(X_test)

# Desnormalizar las predicciones y valores reales si están normalizados
y_pred_test = scaler_y.inverse_transform(y_pred_test)
y_test_actual = scaler_y.inverse_transform(y_test)

# Calcular métricas de evaluación
mse = mean_squared_error(y_test_actual, y_pred_test)
mae = mean_absolute_error(y_test_actual, y_pred_test)
r2 = r2_score(y_test_actual, y_pred_test)

# Mostrar resultados
print("Métricas de Evaluación del Modelo:\n")
print(f"Mean Squared Error (MSE): {mse:.4f}")
print(f"Mean Absolute Error (MAE): {mae:.4f}")
print(f"R2 Score: {r2:.4f}")
```

```
2/2             0s 108ms/step
Métricas de Evaluación del Modelo:

Mean Squared Error (MSE): 266666750765.3382
Mean Absolute Error (MAE): 163980.8349
R2 Score: -0.0111
```

1.6.2 Interpretación

[ ]:
```python
# Interpretación
# Definir umbrales de interpretación para MSE, MAE y R2
def interpretar_mse(mse):
    if mse < 1e7:
        return "Excelente ajuste (MSE muy bajo)"
    elif mse < 1e9:
        return "Buen ajuste (MSE moderado)"
    elif mse < 1e11:
        return "Ajuste aceptable (MSE alto)"
    else:
        return "Ajuste deficiente (MSE muy alto)"

def interpretar_mae(mae):
```

```
    if mae < 1e4:
        return "Error medio bajo (MAE excelente)"
    elif mae < 1e5:
        return "Error medio moderado (MAE aceptable)"
    elif mae < 1e6:
        return "Error medio alto (MAE mejorable)"
    else:
        return "Error medio muy alto (MAE deficiente)"

def interpretar_r2(r2):
    if r2 > 0.9:
        return "Excelente ajuste (R² cercano a 1)"
    elif r2 > 0.7:
        return "Buen ajuste (R² aceptable)"
    elif r2 > 0.5:
        return "Ajuste moderado (R² bajo)"
    elif r2 > 0:
        return "Ajuste bajo (R² muy bajo)"
    else:
        return "El modelo no explica la varianza (R² negativo)"

# Obtener interpretaciones de cada métrica
mse_interpretacion = interpretar_mse(mse)
mae_interpretacion = interpretar_mae(mae)
r2_interpretacion = interpretar_r2(r2)

# Mostrar las métricas con interpretación
print("Métricas de Evaluación del Modelo con Interpretación:")
print(f"\nMean Squared Error (MSE): \n{mse:.4f}\n{mse_interpretacion}")
print(f"\nMean Absolute Error (MAE): \n{mae:.4f}\n{mae_interpretacion}")
print(f"\nR2 Score: \n{r2:.4f}\n{r2_interpretacion}")
```

```
Métricas de Evaluación del Modelo con Interpretación:

Mean Squared Error (MSE):
266666750765.3382
Ajuste deficiente (MSE muy alto)

Mean Absolute Error (MAE):
163980.8349
Error medio alto (MAE mejorable)

R2 Score:
-0.0111
El modelo no explica la varianza (R² negativo)
```

1.7 Generar Predicciones a Fecha Futura

Esta sección es para generar predicciones en datos futuros, donde no se tienen valores reales para comparar.

Aquí no calculamos métricas de evaluación; simplemente obtenemos y almacenamos las predicciones.

1.7.1 Predicción

[ ]:
```
import pandas as pd
import numpy as np

nuevos_nombres_aeropuertos = [
    'Primer_Aeropuerto', 'Segundo_Aeropuerto', 'Tercer_Aeropuerto',
    'Cuarto_Aeropuerto', 'Quinto_Aeropuerto', 'Sexto_Aeropuerto',
    'Séptimo_Aeropuerto', 'Octavo_Aeropuerto', 'Noveno_Aeropuerto',
    'Décimo_Aeropuerto', 'Undécimo_Aeropuerto', 'Duodécimo_Aeropuerto'
]

# Año y mes para la predicción
anio = 2024
mes = 4

# Asegurarse de que los nombres de las columnas coincidan con los utilizados␣
 ↪durante el entrenamiento del scaler
columnas_para_prediccion = ['year', 'month', 'nombre_aeropuerto_encoded']

# Inicializar predicted_df justo antes de generar predicciones
predicted_df = pd.DataFrame()

# Generar y almacenar las predicciones para cada aeropuerto
for aeropuerto in nuevos_nombres_aeropuertos:
    # Obtener el código del aeropuerto con LabelEncoder
    codigo_aeropuerto = le.transform([aeropuerto])[0]

    # Preparar los datos de entrada como DataFrame para mantener los nombres de␣
 ↪las columnas
    new_data_example = pd.DataFrame([[anio, mes, codigo_aeropuerto]],␣
 ↪columns=columnas_para_prediccion)

    # Normalizar los datos usando scaler_X
    new_data_normalized = scaler_X.transform(new_data_example)

    # Hacer la predicción
    prediction = model.predict(new_data_normalized)
    prediction = scaler_y.inverse_transform(prediction)  # Des-normalizar las␣
 ↪predicciones
```

```
    prediction = np.round(prediction).astype(int)  # Redondear y convertir a␣
↪enteros

    # Formatear la fecha para la nueva fila
    fecha_prediccion = f"{anio}-{mes:02d}-30"  # Asume que el día de cierre es␣
↪el último del mes

    # Agregar la predicción al DataFrame
    new_row = pd.DataFrame({
        'nombre_aeropuerto': [aeropuerto],
        'fecha': [fecha_prediccion],
        'numero_aerolineas': [prediction[0, 0]],
        'destinos_nacionales': [prediction[0, 1]],
        'destinos_internacionales': [prediction[0, 2]],
        'destinos_totales': [prediction[0, 1] + prediction[0, 2]],
        'Operaciones_comercial': [prediction[0, 3]],
        'Operaciones_general': [prediction[0, 4]],
        'pasajeros_comercial': [prediction[0, 5]],
        'pasajeros_general': [prediction[0, 6]]
    }, columns=['nombre_aeropuerto', 'fecha', 'numero_aerolineas',␣
↪'destinos_nacionales', 'destinos_internacionales', 'destinos_totales',␣
↪'Operaciones_comercial', 'Operaciones_general', 'pasajeros_comercial',␣
↪'pasajeros_general'])

    predicted_df = pd.concat([predicted_df, new_row], ignore_index=True)

# Mostrar el nuevo DataFrame (primeras filas)
predicted_df.head(25)
```

```
1/1             0s 102ms/step
1/1             0s 18ms/step
1/1             0s 16ms/step
1/1             0s 14ms/step
1/1             0s 14ms/step
1/1             0s 14ms/step
1/1             0s 15ms/step
1/1             0s 16ms/step
1/1             0s 15ms/step
1/1             0s 14ms/step
1/1             0s 15ms/step
1/1             0s 14ms/step
```

[ ]:

	nombre_aeropuerto	fecha	numero_aerolineas	destinos_nacionales	\
0	Primer_Aeropuerto	2024-04-30	12	20	
1	Segundo_Aeropuerto	2024-04-30	13	21	
2	Tercer_Aeropuerto	2024-04-30	13	21	
3	Cuarto_Aeropuerto	2024-04-30	11	19	

```
4      Quinto_Aeropuerto  2024-04-30                13                    21
5       Sexto_Aeropuerto  2024-04-30                13                    21
6     Séptimo_Aeropuerto  2024-04-30                13                    21
7      Octavo_Aeropuerto  2024-04-30                12                    20
8      Noveno_Aeropuerto  2024-04-30                11                    19
9      Décimo_Aeropuerto  2024-04-30                11                    19
10   Undécimo_Aeropuerto  2024-04-30                13                    21
11  Duodécimo_Aeropuerto  2024-04-30                11                    19

    destinos_internacionales  destinos_totales  Operaciones_comercial  \
0                          5                25                  26228
1                          5                26                  26421
2                          5                26                  26661
3                          5                24                  23530
4                          5                26                  26398
5                          5                26                  26456
6                          5                26                  26522
7                          5                25                  26008
8                          5                24                  25353
9                          5                24                  24433
10                         5                26                  26726
11                         5                24                  23979

    Operaciones_general  pasajeros_comercial  pasajeros_general
0                  2261              2818352               7049
1                  2250              2880640               7069
2                  2205              2924545               6803
3                  2240              2511134               5506
4                  2265              2863392               7138
5                  2237              2897904               6999
6                  2224              2914946               6920
7                  2216              2740126               6541
8                  2207              2630733               6135
9                  2223              2564034               5813
10                 2180              2912243               6694
11                 2227              2531270               5667
```

1.7.2 Combinar/Concatenar DataFrames

[ ]:
```python
import pandas as pd

# Concatenar el DataFrame inicial con el de predicciones
combined_df = pd.concat([df, predicted_df], ignore_index=True)

# Convertir la columna 'fecha' a datetime si aún no lo está
combined_df['fecha'] = pd.to_datetime(combined_df['fecha'])
```

```
# Mostrar el DataFrame combinado
combined_df.head()
```

[ ]:
```
       fecha   nombre_aeropuerto tipo_aeropuerto  numero_aerolineas  \
0 2022-03-31   Primer_Aeropuerto   Internacional                 17
1 2022-03-31  Segundo_Aeropuerto   Internacional                  9
2 2022-03-31   Tercer_Aeropuerto   Internacional                 16
3 2022-03-31   Cuarto_Aeropuerto   Internacional                  5
4 2022-03-31   Quinto_Aeropuerto   Internacional                 16

   destinos_nacionales  destinos_internacionales  destinos_total  \
0                   16                         4            20.0
1                   20                         8            28.0
2                   11                         8            19.0
3                   21                         9            30.0
4                   25                         3            28.0

   Operaciones_comercial  Operaciones_general  pasajeros_comercial  \
0                  39158                 3872              2334489
1                  45131                 3019              4572471
2                   3433                 1284              1496025
3                  42434                 1182              3630409
4                   2267                 1628              2528388

   pasajeros_general year_month  year     month  nombre_aeropuerto_encoded  \
0                566    2022-03   0.0  0.181818                   0.454545
1               8422    2022-03   0.0  0.181818                   0.636364
2              12409    2022-03   0.0  0.181818                   0.909091
3               2147    2022-03   0.0  0.181818                   0.000000
4               3990    2022-03   0.0  0.181818                   0.545455

   destinos_totales
0               NaN
1               NaN
2               NaN
3               NaN
4               NaN
```

[ ]:
```
# Info General
combined_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 312 entries, 0 to 311
Data columns (total 16 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   fecha                     312 non-null    datetime64[ns]
```

```
 1   nombre_aeropuerto          312 non-null    object
 2   tipo_aeropuerto            300 non-null    object
 3   numero_aerolineas          312 non-null    int64
 4   destinos_nacionales        312 non-null    int64
 5   destinos_internacionales   312 non-null    int64
 6   destinos_total             300 non-null    float64
 7   Operaciones_comercial      312 non-null    int64
 8   Operaciones_general        312 non-null    int64
 9   pasajeros_comercial        312 non-null    int64
 10  pasajeros_general          312 non-null    int64
 11  year_month                 300 non-null    object
 12  year                       300 non-null    float64
 13  month                      300 non-null    float64
 14  nombre_aeropuerto_encoded  300 non-null    float64
 15  destinos_totales           12 non-null     float64
dtypes: datetime64[ns](1), float64(5), int64(7), object(3)
memory usage: 39.1+ KB
```

[ ]:
```
# Variables (Columnas)
combined_df.columns
```

[ ]:
```
Index(['fecha', 'nombre_aeropuerto', 'tipo_aeropuerto', 'numero_aerolineas',
       'destinos_nacionales', 'destinos_internacionales', 'destinos_total',
       'Operaciones_comercial', 'Operaciones_general', 'pasajeros_comercial',
       'pasajeros_general', 'year_month', 'year', 'month',
       'nombre_aeropuerto_encoded', 'destinos_totales'],
      dtype='object')
```

[ ]:
```
# Configurar la fecha de interés
fecha_interes = pd.to_datetime('2024-04-30')

# Verificar si la fecha de interés está en el DataFrame
fecha_presente = fecha_interes in combined_df['fecha'].values
print("¿Está la fecha '2024-04-30' presente en el DataFrame combinado?:",␣
 ↪fecha_presente)
```

```
¿Está la fecha '2024-04-30' presente en el DataFrame combinado?: True
```

[ ]:
```
# Filtrar el DataFrame para mostrar todas las entradas en la fecha de interés
entradas_fecha_interes = combined_df[combined_df['fecha'] == fecha_interes]
entradas_fecha_interes.head()
```

[ ]:
```
         fecha   nombre_aeropuerto tipo_aeropuerto  numero_aerolineas  \
300 2024-04-30   Primer_Aeropuerto             NaN                 12
301 2024-04-30  Segundo_Aeropuerto             NaN                 13
302 2024-04-30   Tercer_Aeropuerto             NaN                 13
303 2024-04-30   Cuarto_Aeropuerto             NaN                 11
304 2024-04-30   Quinto_Aeropuerto             NaN                 13
```

```
     destinos_nacionales  destinos_internacionales  destinos_total  \
300                   20                         5             NaN
301                   21                         5             NaN
302                   21                         5             NaN
303                   19                         5             NaN
304                   21                         5             NaN

     Operaciones_comercial  Operaciones_general  pasajeros_comercial  \
300                  26228                 2261              2818352
301                  26421                 2250              2880640
302                  26661                 2205              2924545
303                  23530                 2240              2511134
304                  26398                 2265              2863392

     pasajeros_general year_month  year  month  nombre_aeropuerto_encoded  \
300               7049        NaN   NaN    NaN                        NaN
301               7069        NaN   NaN    NaN                        NaN
302               6803        NaN   NaN    NaN                        NaN
303               5506        NaN   NaN    NaN                        NaN
304               7138        NaN   NaN    NaN                        NaN

     destinos_totales
300              25.0
301              26.0
302              26.0
303              24.0
304              26.0
```

[ ]:
```
# Filas y Columnas
combined_df.shape
```

[ ]:
```
(312, 16)
```

1.8 Graficar Proyecciones

Preparación

[ ]:
```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Fechas
combined_df['fecha'] = pd.to_datetime(combined_df['fecha'])
combined_df['year_month'] = combined_df['fecha'].dt.strftime('%Y-%m')

# Agregar una columna para distinguir entre datos históricos y predicciones
combined_df['Tipo'] = 'Histórico'
```

```
combined_df.loc[combined_df['fecha'] >= '2024-04-30', 'Tipo'] = 'Predicción'
```

1.8.1 Verificar Duplicados

[ ]:
```
# Filtrar por la fecha de predicción y verificar duplicados
fecha_prediccion = '2024-04'
predicciones_abril_2024 = combined_df[combined_df['year_month'] ==␣
 ↪fecha_prediccion]
print("Predicciones:")
print(predicciones_abril_2024[['nombre_aeropuerto', 'year_month',␣
 ↪'Operaciones_comercial', 'Tipo']])

# Verificar si hay duplicados en la fecha de predicción
duplicados = predicciones_abril_2024.duplicated(subset=['nombre_aeropuerto',␣
 ↪'year_month'], keep=False)
print("\nPredicciones Duplicadas:\n")
print(predicciones_abril_2024[duplicados])
```

```
Predicciones:
        nombre_aeropuerto year_month  Operaciones_comercial        Tipo
300      Primer_Aeropuerto    2024-04                  26228  Predicción
301     Segundo_Aeropuerto    2024-04                  26421  Predicción
302      Tercer_Aeropuerto    2024-04                  26661  Predicción
303      Cuarto_Aeropuerto    2024-04                  23530  Predicción
304      Quinto_Aeropuerto    2024-04                  26398  Predicción
305       Sexto_Aeropuerto    2024-04                  26456  Predicción
306     Séptimo_Aeropuerto    2024-04                  26522  Predicción
307      Octavo_Aeropuerto    2024-04                  26008  Predicción
308      Noveno_Aeropuerto    2024-04                  25353  Predicción
309      Décimo_Aeropuerto    2024-04                  24433  Predicción
310    Undécimo_Aeropuerto    2024-04                  26726  Predicción
311  Duodécimo_Aeropuerto    2024-04                  23979  Predicción

Predicciones Duplicadas:

Empty DataFrame
Columns: [fecha, nombre_aeropuerto, tipo_aeropuerto, numero_aerolineas,
destinos_nacionales, destinos_internacionales, destinos_total,
Operaciones_comercial, Operaciones_general, pasajeros_comercial,
pasajeros_general, year_month, year, month, nombre_aeropuerto_encoded,
destinos_totales, Tipo]
Index: []
```

1.8.2 Tendencia de Operaciones Comerciales

[ ]:
```
# Graficar Tendencia de Operaciones Comerciales

# Importar
import seaborn as sns
import matplotlib.pyplot as plt

# Calcular la media de Operaciones Comerciales por aeropuerto
media_operaciones = combined_df.
 ↪groupby('nombre_aeropuerto')['Operaciones_comercial'].mean()

# Configuración de Seaborn
sns.set(style="white")

# Crear el FacetGrid
g = sns.FacetGrid(combined_df, col='nombre_aeropuerto', col_wrap=4, height=3,␣
 ↪aspect=1.5)

# Definir paleta de colores
palette = {'Histórico': '#4287f5', 'Predicción': '#f54242'}

# Mapear gráficos para cada subgráfico del grid
for ax, (name, group) in zip(g.axes.flat, combined_df.
 ↪groupby('nombre_aeropuerto')):
    sns.lineplot(data=group, x='year_month', y='Operaciones_comercial',␣
 ↪hue='Tipo', palette=palette, ax=ax, legend=False)
    sns.scatterplot(data=group[group['Tipo'] == 'Predicción'], x='year_month',␣
 ↪y='Operaciones_comercial', hue='Tipo', palette=palette, ax=ax, s=50,␣
 ↪legend=False)

    # Agregar una línea horizontal con la media de Operaciones Comerciales para␣
 ↪cada aeropuerto
    ax.axhline(y=media_operaciones[name], color='gray', linestyle='--',␣
 ↪linewidth=1, label='Media')

# Ajustar detalles de gráficos
g.set_titles('{col_name}')
g.set_axis_labels('Fecha', 'Operaciones Comerciales')
for ax in g.axes.flatten():
    ax.tick_params(labelrotation=45)

# Ajustar espacio y título general
plt.subplots_adjust(top=0.85)
g.fig.suptitle('Tendencia de Operaciones Comerciales por Aeropuerto',␣
 ↪fontsize=16)
```

```
# Configurar leyenda global
handles, labels = g.axes[-1].get_legend_handles_labels()
if handles:
    g.fig.legend(handles=handles, labels=labels, loc='upper center', ncol=3,␣
 ↪title='Tipo', bbox_to_anchor=(0.5, 0.95))
else:
    print("Histórico: Líneas")
    print("Predicción: Puntos")
    print("Media: Línea discontinua gris")

# Mostrar el gráfico
plt.show()
```

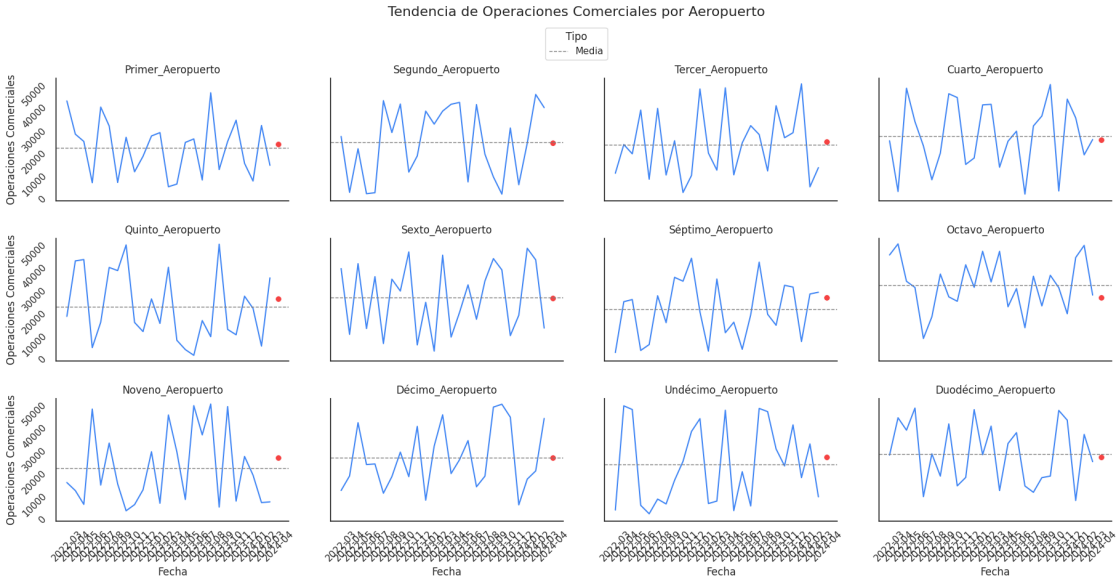

1.9 Exportar CSV con Histórico y Proyecciones

[ ]:
```
# Exportar el DataFrame actualizado a CSV
combined_df.to_csv('datos_aeropuertos_predicciones.csv', index=False)
```

1.10 Fin